

State of the Art

Analiza imaginilor cu fund de ochi pentru ajutor în diagnosticul retinopatiei diabetice

1. Introducere

Retinopatia diabetică reprezintă o complicație oculară severă a diabetului zaharat, ce poate avea un impact semnificativ asupra sănătății vizuale. Aceasta se manifestă prin afectarea progresivă a vaselor de sânge ale retinei, determinând apariția edemelor, hemoragiilor și a altor anomalii la nivelul retinei. Dacă nu este identificată și tratată la timp, boala poate conduce la pierderea ireversibilă a vederii. Diagnosticul precoce și intervenția terapeutică adecvată sunt factori esențiali în reducerea deteriorării vederii.

Metodele standard de diagnosticare presupun examinarea imaginilor fundului de ochi prin oftalmoscopie sau angiografie cu fluoresceină, însă procesul de analiză a acestor imagini este în mare parte manual și depinde de expertiza oftalmologilor. Din această cauză, timpul necesar pentru interpretarea imaginilor și clasificării severității bolii poate varia, iar erorile de diagnostic nu sunt excluse. În acest context, utilizarea algoritmilor de inteligență artificială bazati pe învățare profundă devin o soluție promițătoare pentru optimizarea procesului de detecție și clasificare a retinopatiei diabetice.

În ultimele decenii, rețelele neuronale convoluționale au demonstrat un potențial semnificativ în analiza automată a imaginilor medicale. Acestea au capacitatea de a extrage caracteristici relevante din imagini și de a clasifica severitatea leziunilor cu o precizie comparabilă sau chiar superioară specialiștilor umani. De asemenea, utilizarea unor seturi de date publice adnotate permit antrenarea și validarea modelelor, asigurând astfel un cadru robust pentru diagnosticare. Având în vedere aceste progrese tehnologice, integrarea metodelor automatizate ar putea îmbunătăți considerabil acuratețea și eficiența diagnosticării retinopatiei diabetice.



Fig. 1. Diferite forme de retinopatie diabetică

2. Detectarea retinopatiei diabetice

Detectarea automată a retinopatiei diabetice a înregistrat progrese semnificative datorită utilizării rețelelor neuronale convoluționale, care permit identificarea rapidă și precisă a anomaliilor din imagini. Aceste modele sunt instruite pe seturi de date extinse, precum EyePACS și IDRiD, și sunt utilizate frecvent datorită capacității lor de a diferenția nivelurile de severitate ale bolii. Printre arhitecturile cele mai eficiente se numără VGG16, ResNet și EfficientNet, fiecare având rolul de a extrage și analiza caracteristici relevante din imagini.

În cazurile în care este necesară evaluarea evoluției bolii în timp, rețelele CNN sunt integrate cu modele recurente, precum GRU și LSTM, care pot analiza relațiile temporale dintre imaginile colectate la diferite intervale. În plus, metodele avansate de segmentare, cum ar fi U-Net, Mask R-CNN și DeepLabV3+, sunt utilizate pentru identificarea și evidențierea zonelor afectate, oferind o interpretare mai clară a severității leziunilor.

3. Extracția și analiza caracteristicilor relevante

Pentru detectarea și clasificarea retinopatiei diabetice (RD), etichetele asociate imaginilor din seturile de date joacă un rol esențial. Acestea permit modelelor să învețe caracteristicile relevante ale bolii, să distingă între diferite grade de severitate și să identifice leziunile retiniene specifice. Calitatea și structura acestor etichete influențează direct performanța modelelor și capacitatea acestora de a generaliza asupra unor date noi.

În general, etichetele din seturile de date ce vizează retinopatia diabetică sunt structurate în mai multe categorii, fiecare având o contribuție specifică la dezvoltarea algoritmilor de detecție. Printre acestea se numără:

- Etichetele pentru clasificarea severității bolii;
- Etichetele pentru segmentarea leziunilor;
- Etichetele pentru localizarea structurilor.

Totodată, etichetele utilizate în seturile de date vin și cu o serie de provocări care pot influența performanța algoritmilor. Unul dintre cele mai mari obstacole îl reprezintă inconsistența etichetării, întrucât diagnosticul retinopatiei diabetice implică un grad semnificativ de interpretare subiectivă. Diferențele de opinie dintre specialiști pot duce la variații în adnotările imaginilor, ceea ce afectează acuratețea modelelor antrenate pe astfel de date.

O altă provocare majoră o reprezintă dezechilibrul claselor, deoarece în multe seturi de date numărul de imagini cu funduri de ochi ce prezintă retinopatie diabetică severă este considerabil mai mic decât cel al imaginilor sănătoase sau al celor cu forme incipiente ale bolii. Acest dezechilibru poate determina modelele să favorizeze predicțiile pentru clasele mai frecvente, ignorând cazurile rare, dar critice. Pentru a compensa această problemă, sunt aplicate metode precum re-eșantionarea datelor, ponderarea claselor în funcția de pierdere a modelului sau generarea de imagini sintetice.




Fig. 2. Diferența dintre o retină sănătoasă și o retinopatie diabetică

4. Seturi de date

După cum am amintit în punctul anterior, calitatea etichetării și structura seturilor de date joacă un rol esențial în detectarea retinopatiei diabetice. În acest sens, au fost create și utilizate multiple seturi de imagini ce vizează retinopatia diabetică, menite să sprijine atât antrenarea, cât și evaluarea performanței algoritmilor de învățare automată. Aceste seturi de date diferă în funcție de dimensiunea și nivelul detaliilor oferite în adnotări. În continuare, vor fi analizate două seturi de date utilizate în acest domeniu, evidențiind caracteristicile lor principale și modul în care contribuie la îmbunătățirea metodelor de detecție a retinopatiei diabetice.

a) Setul de date IDRiD

Indian Diabetic Retinopathy Image Dataset (IDRiD) reprezintă unul dintre cele mai utilizate seturi de date, fiind conceput pentru a sprijini cercetarea în diagnosticarea și clasificarea retinopatiei diabetice. Acesta este structurat în trei părți, fiecare având un rol distinct în analiza imaginilor. Prima componentă include imagini etichetate pentru clasificarea severității bolii, oferind informații despre stadiul retinopatiei diabetice și prezența edemului macular. Acest aspect este esențial pentru dezvoltarea modelelor de învățare automată astfel încât acestea să distingă între diferite niveluri de afectare oculară. A doua componentă este destinată segmentării leziunilor, conținând adnotări precise la nivel de pixel pentru principalele anomalii vizuale, cum ar fi microanevrismele, hemoragiile și exudatele. Aceasta permite antrenarea modelelor capabile să localizeze și să analizeze zonele afectate din retină, facilitând un diagnostic mai detaliat. În cele din urmă, a treia componentă este reprezentată de informațiile cu privire la localizarea structurilor anatomice ale retinei. Datorită calității imaginilor, etichetării detaliate, diversității și utilizării în cercetare, IDRiD este un set de date esențial pentru dezvoltarea modelelor dedicate diagnosticării retinopatiei diabetice. Acesta oferă un cadru ideal pentru antrenarea algoritmilor de clasificare și segmentare, contribuind la îmbunătățirea tehnologiilor de diagnostic automatizat.

b) Setul de date Diabetic Retinopathy 224x224

Diabetic Retinopathy 224x224 (2019 Data) reprezintă un alt set de date utilizat în detectarea retinopatiei diabetice, însă care conține imagini preprocesate, redimensionate la 224x224 pixeli, ce facilitează antrenarea modelelor de învățare profundă printr-un format standardizat. Etichetarea imaginilor este realizată conform unui sistem clar de clasificare a severității bolii, împărțind datele în cinci categorii distincte. O imagine poate fi considerată normală, fără semne de retinopatie diabetică, sau poate prezenta diferite stadii de evoluție a bolii. În cazul retinopatiei diabetice ușoare, sunt vizibile

doar microanevrisme, în timp ce în stadiul moderat apar și hemoragii, precum și primele semne ale exudatelor. Retinopatia severă se caracterizează prin prezența anomaliilor vasculare multiple, iar în forma proliferativă, cea mai avansată, pot fi observate vase de sânge anormale și alte complicații care cresc riscul de pierdere a vederii.

De menționat faptul că, datorită dimensiunii reduse a imaginilor, setul este potrivit pentru utilizarea pe sisteme cu resurse limitate, însă acest lucru poate duce la pierderea unor detalii fine, esențiale în diagnosticarea timpurie. Cu toate acestea, setul de date rămâne o resursă valoroasă pentru dezvoltarea algoritmilor de clasificare a retinopatiei diabetice, fiind frecvent utilizat.

5. Studii similare

În articolul ["Diabetic Retinopathy Detection via Deep Convolutional Networks for Discriminative Localization and Visual Explanation"](#) de Zhiguang Wang și Jianbo Yang, autorii propun o metodă de învățare profundă pentru detectarea retinopatiei diabetice care oferă interpretabilitate vizuală. Această caracteristică este realizată prin adăugarea unei hărți de activare a regresiei (Regression Activation Map - RAM) după stratul de pooling al rețelelor neuronale convoluționale. RAM permite modelului să localizeze regiunile discriminative ale unei imagini ce ilustrează retina, evidențiind zonele de interes în funcție de nivelul de severitate al retinopatiei diabetice. Această abordare nu doar că îmbunătățește performanța predicției, dar oferă și explicații vizuale asupra deciziilor modelului, aspect esențial în practica medicală. Experimentele realizate pe un set larg de imagini au demonstrat că modelul propus atinge performanțe ridicate în detectarea retinopatiei diabetice, oferind în același timp hărți de activare care evidențiază regiunile semnificative ale imaginii de intrare.

În lucrarea ["nnMobileNet: Rethinking CNN for Retinopathy Research"](#), autorii propun o actualizare a arhitecturii MobileNet pentru a îmbunătăți diagnosticarea retinopatiei diabetice. Deși modelele bazate pe Vision Transformers (ViT) au demonstrat performanțe remarcabile în acest domeniu, acestea necesită resurse computaționale semnificative și volume mari de date pentru antrenare. În contrast, autorii au optimizat MobileNet prin modificări selective, obținând performanțe superioare față de modelele ViT în diverse benchmark-uri RD, inclusiv clasificarea retinopatiei diabetice, detectarea multiplă a bolilor fundului de ochi și clasificarea edemului macular.

6. Concluzii

În concluzie, această lucrare a analizat metodele actuale de detectare a retinopatiei diabetice, evidențiind progresele realizate prin utilizarea rețelelor neuronale convoluționale și provocările asociate, precum etichetarea datelor și dezechilibrul claselor. De asemenea, s-a subliniat importanța unor seturi de date bine structurate, precum IDRiD și Diabetic Retinopathy 224x224, în antrenarea modelelor și îmbunătățirea preciziei diagnosticului. Analiza celor două studii de specialitate a arătat că modelele reușesc să atingă performanțe ridicate. Totuși, provocările legate de calitatea datelor, dezechilibrul claselor și etichetarea variabilă rămân aspecte ce necesită optimizare. De asemenea, dezvoltarea unor modele, care să îmbine analiza imaginilor cu date clinice relevante și integrarea acestor soluții în fluxurile de lucru medicale ar putea sprijini medicii în luarea deciziilor, reducând astfel variabilitatea diagnosticelor și optimizând procesul de screening. Prin urmare, este esențial ca viitoarele cercetări să se concentreze pe optimizarea performanței modelelor, îmbunătățirea interpretabilității acestora și creșterea fiabilității datelor utilizate.

7. Bibliografie

- [1]: Zhiguang Wang, Jianbo Yang – "Diabetic Retinopathy Detection via Deep Convolutional Networks for Discriminative Localization and Visual Explanation"
- [2]: Wenhui Zhu, Peijie Qiu, Xiwen Chen, Xin Li¹, Natasha Lepore, Oana M. Dumitrascu, Yalin Wang - "nnMobileNet: Rethinking CNN for Retinopathy Research"
- [3]: Pratt Harry, Coenen Frans, Deborah M Broadbent, Simon P. Harding, Zheng, Y. - "Convolutional Neural Networks for Diabetic Retinopathy"
- [4]: Prasanna Porwal, Samiksha Pachade, Ravi Kamble, Manesh Kokare, Girish Deshmukh, Vivek Sahasrabuddhe, Fabrice Meriaudeau - "Indian Diabetic Retinopathy Image Dataset"